CYBERCLUSTER — DESCOBERTA DE PADRÕES EM TRÁFEGO DE REDE USANDO DBSCAN

Samuel Esperança Vieira Panobianco · Bryan Williams Souto Silva · Lucas Miguel Cardoso de Almeida · Renan Denadai de Paula

Faculdades Integradas de Bauru – FIB · Ciência da Computação

Disciplina: Inteligência Artificial II · Checkpoint 1 – CONSTRUIR · Prof. Ronaldo Dametto

---

RESUMO

Este trabalho propõe o **CyberCluster**, um protótipo em Python que aplica o algoritmo **DBSCAN** a registros de conexões de rede do dataset público **CICIDS2017** para descobrir grupos de comportamento semelhante e isolar conexões que não se encaixam em nenhum grupo (ruído). Os resultados serão exibidos em gráficos interativos construídos com **Streamlit**, e o DBSCAN será comparado ao **K-Means** como baseline. Os rótulos do dataset (tráfego normal e tipos de ataque) não são usados no treinamento; servem apenas para verificar se os agrupamentos descobertos têm relação com os tipos de tráfego conhecidos. Este rascunho apresenta a introdução, os objetivos, a relevância, a metodologia e os resultados preliminares.

Palavras-chave: DBSCAN; agrupamento; tráfego de rede; CICIDS2017; detecção de anomalias.

1. INTRODUÇÃO

Redes de computadores geram, a cada segundo, grandes volumes de **conexões (fluxos)** descritas por medidas como duração, quantidade de pacotes, bytes transmitidos e tempo entre pacotes. Quem opera uma rede precisa entender o que é comportamento habitual e o que foge do esperado, mas examinar milhões de registros manualmente é inviável e, na prática, nem sempre há rótulos confiáveis que digam quais conexões são maliciosas.

O **agrupamento (clustering)** é uma técnica de aprendizado não supervisionado que organiza os dados em grupos de similaridade sem usar rótulos. Entre os algoritmos existentes, o **DBSCAN** (Ester et al., 1996) é baseado em densidade: forma grupos em regiões onde os pontos são

numerosos e próximos, aceita grupos de formato arbitrário, não exige que se informe antes o número de grupos e marca como **ruído** os pontos que ficam em regiões esparsas. Essas características o tornam candidato natural para explorar tráfego de rede, em que há comportamentos dominantes e um conjunto de casos incomuns. Schubert et al. (2017) discutem por que e como o DBSCAN ainda deve ser usado, inclusive a sensibilidade de seus parâmetros, que será um dos focos do projeto.

Importante: uma conexão classificada como ruído **não é necessariamente um ataque**. O ruído indica apenas que o ponto é raro em relação aos grupos encontrados. Por isso, o projeto não promete um detector de intrusões, e sim uma investigação de quanto os grupos descobertos se relacionam com os tipos de tráfego registrados no dataset.

2. OBJETIVOS

Pergunta de investigação: os agrupamentos que o DBSCAN encontra em conexões de rede, sem acesso aos rótulos, correspondem aos tipos de tráfego do CICIDS2017, e como a escolha dos parâmetros altera esse resultado?

Objetivo geral: descobrir padrões de comportamento em tráfego de rede e identificar conexões atípicas por meio de agrupamento baseado em densidade, apresentando os resultados em um protótipo interativo.

Objetivos específicos:

- preparar o dataset (limpeza, tratamento de valores inválidos e padronização) de forma justificada e reproduzível;
- aplicar o DBSCAN e analisar como **eps** e **min_samples** afetam o número de grupos e a proporção de ruído;
- comparar o DBSCAN com o **K-Means** (baseline) usando métricas internas e a comparação com os rótulos conhecidos;
- verificar quais tipos de tráfego (normal e ataques) concentram-se em cada grupo e no ruído;
- disponibilizar um protótipo em **Streamlit** com gráficos interativos dos grupos e dos pontos de ruído.

3. RELEVÂNCIA DO ESTUDO

Em segurança da informação, analistas lidam com grande quantidade de registros e poucos exemplos rotulados de ataques novos. Técnicas não supervisionadas ajudam a **resumir o comportamento da rede** e a destacar casos que merecem atenção, apoiando a triagem de eventos. O estudo também tem valor didático e científico por avaliar com honestidade os limites do método: o DBSCAN depende de parâmetros e da escala das variáveis, e o ruído nem sempre é malicioso. Além disso, o CICIDS2017 já foi alvo de análise crítica, com problemas apontados na construção dos

fluxos e na rotulagem (Engelen; Rimmer; Joosen, 2021), o que reforça a necessidade de inspecionar a qualidade dos dados antes de interpretar qualquer agrupamento.

4. MATERIAIS E MÉTODOS (PRELIMINAR)

Dataset. Será utilizado o **CICIDS2017**, do Canadian Institute for Cybersecurity (Universidade de New Brunswick), descrito por Sharafaldin, Lashkari e Ghorbani (2018). Os dados foram coletados durante cinco dias (3 a 7 de julho de 2017); a segunda-feira contém apenas tráfego normal e os demais dias combinam tráfego normal com ataques, entre eles força bruta FTP e SSH, DoS, Heartbleed, ataques web, infiltração, botnet, DDoS e varredura de portas. Cada fluxo é descrito por mais de 80 características e possui rótulo. Serão usados os arquivos CSV preparados para aprendizado de máquina. Nos experimentos preliminares, foi usada uma amostra estratificada de 2.000 a 10.000 conexões com 78 atributos numéricos contínuos, incluindo tráfego normal (Benign), ataques volumétricos (DDoS) e varreduras de portas (PortScan).

Preparação dos dados. Planejam-se: (i) padronização dos nomes de colunas; (ii) tratamento de valores infinitos e ausentes, que surgem em colunas de taxa (bytes/s e pacotes/s); (iii) remoção de registros duplicados e de colunas constantes ou repetidas; (iv) exclusão de colunas de identificação (como endereços e carimbo de tempo), para que o agrupamento reflita comportamento e não identidade; e (v) **padronização (StandardScaler)**, pois DBSCAN e K-Means dependem de distância e são sensíveis à diferença de escala. Como o DBSCAN tem custo elevado em grandes volumes, será usada **amostragem estratificada** por dia/tipo de tráfego, e a redução de dimensionalidade (PCA) será usada apenas para visualização em 2D.

Prevenção de vazamento de dados. A coluna de rótulo **não entra** como característica em nenhum algoritmo; ela é usada somente depois do agrupamento, para avaliação. Os parâmetros do padronizador serão aprendidos apenas com a amostra de ajuste, e não com toda a base.

Algoritmos e baseline. O **DBSCAN** (Ester et al., 1996) será executado com a implementação do scikit-learn (Pedregosa et al., 2011); o valor de **eps** será orientado pelo gráfico de distância ao k-ésimo vizinho e explorado em uma grade de valores, variando também **min_samples**. O **baseline** é o **K-Means** (Lloyd, 1982), escolhido por ser simples, amplamente conhecido e por exigir o número de grupos como parâmetro, o que permite contrastar com o DBSCAN, que o descobre sozinho e separa ruído.

Avaliação. Métricas internas: coeficiente de silhueta (Rousseeuw, 1987), calculado sem os pontos de ruído, número de grupos e proporção de ruído. Métricas externas, usando os rótulos apenas para conferência:

pureza dos grupos, índice de Rand ajustado e distribuição dos tipos de tráfego dentro de cada grupo e no ruído.

Protótipo. Aplicação em **Streamlit** com controle dos parâmetros, gráficos interativos dos grupos e do ruído e comparação lado a lado com o K-Means. Não serão montadas redes, executados ataques nem criados servidores: o trabalho usa apenas dados já coletados. O código, o README e as instruções para obter o dataset ficarão em repositório no GitHub: https://github.com/samunewage/CyberClusterDBSCAN.

5. RESULTADOS PRELIMINARES

Na preparação dos dados, foram removidos registros com valores infinitos ou nulos (causados por divisões por zero nas taxas de transmissão), registros duplicados e atributos sem variação. As variáveis de identificação (IPs, portas e carimbo de tempo) foram descartadas e o rótulo de classe ficou fora do ajuste dos algoritmos.

No baseline **K-Means** (k = 3), a silhueta foi de 0,4902 e o ARI de 0,6876. O resultado mostra a limitação do algoritmo, que força todos os pontos a entrar em grupos esféricos, inclusive as conexões atípicas, que acabam puxando o centro do tráfego normal.

O **DBSCAN**, com o valor de eps estimado pelo gráfico de k-distâncias, encontrou 7 grupos homogêneos no cenário misto (Benign, DDoS e PortScan) e separou 2,85% das conexões como ruído (rótulo -1). Apenas no PortScan, obteve ARI de 0,9682 e silhueta de 0,6532, isolando as conexões atípicas sem usar rótulos no treinamento. Como já dito, ruído não significa necessariamente ataque.

6. PRÓXIMOS PASSOS

Para 03/11, pretende-se investigar **por que** os resultados do DBSCAN aconteceram e **como saber se são bons**: sensibilidade a eps e min_samples, efeito da padronização e da amostragem, e quais tipos de ataque ficam em grupos próprios, misturados ao tráfego normal ou no ruído. Como próximos passos, pretende-se avaliar a robustez do DBSCAN frente a ataques com densidades muito diferentes e investigar o efeito da redução de dimensionalidade com PCA na separação dos grupos.

REFERÊNCIAS

ENGELEN, G.; RIMMER, V.; JOOSEN, W. Troubleshooting an Intrusion Detection Dataset: the CICIDS2017 Case Study. In: IEEE Security and Privacy Workshops (SPW), 2021. DOI: 10.1109/SPW53761.2021.00009.

ESTER, M.; KRIEGEL, H.-P.; SANDER, J.; XU, X. A density-based algorithm for discovering clusters in large spatial databases with noise. In: Proceedings of the 2nd International Conference on Knowledge Discovery and Data Mining (KDD-

96), 1996. p. 226–231. Disponível em: https://www.aaai.org/Papers/KDD/1996/KDD96-037.pdf.

LLOYD, S. P. Least squares quantization in PCM. IEEE Transactions on Information Theory, v. 28, n. 2, p. 129–137, 1982. DOI: 10.1109/TIT.1982.1056489.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. Journal of Machine Learning Research, v. 12, p. 2825–2830, 2011. Disponível em: https://jmlr.org/papers/v12/pedregosa11a.html.

ROUSSEEUW, P. J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. Journal of Computational and Applied Mathematics, v. 20, p. 53–65, 1987. DOI: 10.1016/0377-0427(87)90125-7.

SCHUBERT, E.; SANDER, J.; ESTER, M.; KRIEGEL, H.-P.; XU, X. DBSCAN revisited, revisited: why and how you should (still) use DBSCAN. ACM Transactions on Database Systems, v. 42, n. 3, art. 19, p. 19:1–19:21, 2017. DOI: 10.1145/3068335.

SHARAFALDIN, I.; LASHKARI, A. H.; GHORBANI, A. A. Toward generating a new intrusion detection dataset and intrusion traffic characterization. In: 4th International Conference on Information Systems Security and Privacy (ICISSP), Portugal, 2018. Artigo: https://www.scitepress.org/Papers/2018/66398/66398.pdf. Dataset: https://www.unb.ca/cic/datasets/ids-2017.html.

STREAMLIT. Documentação oficial. Disponível em: https://docs.streamlit.io.